

# テキスト分析

福田真人

*“Digital History and Argument”*

*“The Differences between Digital Humanities and Digital History”*

「計量テキスト分析およびKH Coderの利用状況と展望」

# Digital History and Argument ①

テキスト分析: 広く利用されるデジタルヒストリー手法  
アルゴリズム依存の非価値中立的な手法

Topic modeling : トピックの出現率・分布・トピックの傾向

Word-embedded modeling : 単語・語群を空間上に表現  
ネットワーク分析と関連

Identifying text reuse : 引用などの特定  
cf) 百科全書

# Digital History and Argument ②

“Stir the archives”

優位点：テキストの連続性と非連続性

パターンと例外

⇒時代区分論

長期・大量のテキスト分析

イギリス議会文書・裁判記録などの事例

# Digital History and Argument ②

“Stir the archives”

優位点：テキストの連続性と非連続性

パターンと例外

⇒時代区分論

長期・大量のテキスト分析

イギリス議会文書・裁判記録などの事例

# The Differences between Digital Humanities and Digital History ①

テキスト分析：一定の利用 but 歴史分野では限定的な面も  
仮説なしボトムアップ法という画期性（？）  
研究者が読まない単語をチェック可能

テキストデータ量の制約 検索用データの傾向  
文学に比べ非印刷物の利用度合いが高い  
API化やオープンデータ化の欠如 商業ソフト依存  
文脈によらない 階層理解の欠如 サーチ単語の妥当性問題

# The Differences between Digital Humanities and Digital History ②

新聞データベース Chronicling America project

利用規約自由 データに欠損（新聞の種類・時期）

著作権やOCRの正確性といった問題

新聞以外の少数のテキスト分析（外交・ジェンダー・投票等）

歴史学者の方法論・デジタルソースへの信用が

研究の進展・データの拡充に重要

歴史学者の理解を得るためには人文情報学ではなく、

細分化されたデジタルヒストリーを軸にすべき

# 計量テキスト分析およびKH Coderの利用状況と展望 ①

テキスト分析の目的：データ探索・信頼性の向上

事例：Twitter 雑誌（アサヒ芸能等）

アンケート インタビュー 会議録

共通の枠組みの必要性（時期・年代の曖昧性？）

比較できる論点

今後の展望：利用例の提示

オープンアクセスの維持

# 計量テキスト分析およびKH Coderの利用状況と展望 ②

『性・メディア・風俗——週刊誌『アサヒ芸能』から  
みる風俗としての性』

雑誌の目次タイトルから性風俗の分析

コーディングルールの仮説・検証

目録からの研究可能性



# 計量テキスト分析およびKH Coderの利用状況と展望 ③

「ポスト保革イデオロギー時代における日本政治の対立軸——『保革溶解』の逸脱事例としての沖縄を中心に」  
基本は歴史学的分析で、補完的に計量文献学を利用  
仮説からコーディングルールを整備  
議事録（全文テキスト化済）から分析  
発話者別の分析で階層化に成功している